

INTELIGÊNCIA ARTIFICIAL


REDES NEURAIS ARTIFICIAIS



Krigor R. Rosa da Silva
krigor.silva@edu.udesc.br



Complexidade de RNA



● **Bias** tem a ver com as simplificações feitas pelo modelo para facilitar o aprendizado, a tendência do modelo em prever erroneamente.

● **Variância** se refere a sensibilidade do modelo às variações nos dados, quão espalhadas estão as respostas



Complexidade de RNA

- Interação entre a estrutura da rede e os parâmetros ajustáveis



Complexidade de RNA

- Interação entre a estrutura da rede e os parâmetros ajustáveis
 - Arquitetura da rede
 - Número de camadas
 - Número de neurônios por camadas
 - Funções de ativação
 - Base de Dados
 - Dimensionalidade
 - Dados desbalanceados
 - Relações não lineares

$$y = g(x_1w_1 + x_2w_2 + x_3w_3 + \theta_1)$$

$$y = g(g((x_1w_1 + x_2w_2 + \theta_1))w_5 + g((x_1w_3 + x_2w_4 + \theta_1))w_6 + \theta_2)$$



Técnicas de Regularização

- Técnicas aplicadas no treinamento com o objetivo de evitar o overfitting
- Objetivo é melhorar a generalização do modelo
- Principais técnicas:
 - Regularização L1 e L2
 - Dropout
 - Aumento dos dados



Técnicas de Regularização

Regularização L1 e L2

- Adicionam termos de penalidade na função de perda durante o treinamento do modelo
- A regularização L1 introduz uma penalidade proporcional ao valor absoluto dos pesos do modelo
- A regularização L2 introduz uma penalidade proporcional ao quadrado dos coeficientes.
 - Isso ajuda a evitar que os pesos do modelo se tornem muito grandes.

$$\text{RSS} = \sum_{i=1}^n [y_i - (\mathbf{w} \cdot \mathbf{x}_i + b)]^2, \quad \boxed{+ \alpha \sum_{j=1}^p |w_j|}$$

regularização ℓ_1

$$\text{RSS} = \sum_{i=1}^n [y_i - (\mathbf{w} \cdot \mathbf{x}_i + b)]^2, \quad \boxed{+ \alpha \sum_{j=1}^p w_j^2}$$


regularização ℓ_2




Técnicas de Regularização

Dropout

- Desativa aleatoriamente um número especificado (pelo usuário) de neurônios durante cada passagem do treinamento
- Objetivo reduzir dependência entre neurônios



(a) Standard Neural Net



(b) After applying dropout.



Técnicas de Regularização

Aumento dos dados (Data augmentation)

- Usado para imagens
- Envolve a criação de novos dados de treinamento artificialmente por meio de pequenas alterações ou transformações nas amostras de dados existentes
 - Rotações, reflexões, zoom, deslocamentos, alterações de brilho e contraste, entre outros.
- Objetivo é expor o modelo a mais variações nos dados de treinamento
 - Ajuda a melhorar a capacidade de generalização do modelo
 - Permite que o modelo aprenda características mais gerais em vez de características específicas dos dados de treinamento existentes



Métricas de performance

- É importante usar métricas para avaliar um modelo de machine learning
 - Até agora vimos somente a função de custo (Erro)
 - Outras métricas podem ser usadas para melhor avaliação e entendimento do modelo
- Para Classificação
 - Acuracidade, precisão, sensibilidade, F1-score, Curvas ROC, ...
- Para Regressão
 - MAE, MSE, RMSE, ...



Métricas de performance

Acuracidade

- Medida do grau de aproximação de um determinado conjunto de dados do nosso modelo do seu verdadeiro valor.

$$Acuracidade = \frac{\textit{Classificações corretas}}{\textit{Todas as classificações}}$$


- Ex.: Se um modelo faz 10 previsões e 9 corretas, sua acuracidade é de 90%
- É a proporção de previsões corretas entre o número total de casos examinados



Métricas de performance

Acuracidade

- Para classes enviesadas/desbalanceado, a métrica de precisão pode ser enganadora
- Se tivermos um conjunto de dados (95% classe A e 5% classe B) o modelo pode prever todas as instâncias como pertencentes à classe A e ainda assim ter uma acurácia de 95%. No entanto, isso não significa que o modelo esteja realmente funcionando bem, uma vez que ele não está identificando corretamente as instâncias da classe B.





Métricas de performance

Matriz de Confusão

- Busca entender a relação entre acertos e erros que o modelo apresenta

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

- Verdadeiro Positivo (True Positive – TP)** – Classe prevista e observada originalmente fazem parte da classe positiva;
- Falso Positivo (False Positive – FP)** – Classe predita retornou positivo mas a original observada era negativa;
- Verdadeiro Negativo (True Negative – TN)** – Valores preditos e observados fazem parte da categoria negativa;
- Falso Negativo (False Negative – FN)** – Representa que o valor predito resultou na classe negativa mas o original observado era da classe positivo.



Métricas de performance

Matriz de Confusão

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Precisão: Quantidade Positiva classificada corretamente

- De todos os dados classificados como A, que fração é realmente da classe A?

$$\text{Precisão} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

Sensibilidade: Taxa de valores classificada como Positivo, comparada com quantos deveriam ser

- De todos os dados que são da classe A, que fração detectámos corretamente como pertencendo a classe?

$$\text{Sensibilidade} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$



Métricas de performance

Matriz de Confusão

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

F1-Score: É calculado como a média harmônica entre Precisão e Recall

$$F1\ Score = \frac{2 * Precisão * Sensibilidade}{Precisão + Sensibilidade}$$


- É benéfico quando se lida com conjuntos de dados desequilibrados, em que uma classe é significativamente mais frequente do que a outra.



Métricas de performance

Curva ROC (Receiver Operating Characteristic)

- A curva ROC mostra o quão bom o modelo criado pode distinguir entre duas coisas
- Regressão logística
 - Calcular a probabilidade de uma determinada classe
 - Variação do valor de corte









Métricas de performance

Curva ROC (Receiver Operating Characteristic)

● Possui dois parâmetros:

- Taxa de verdadeiro positivo = Precisão
- Taxa de falso positivo = sensibilidade






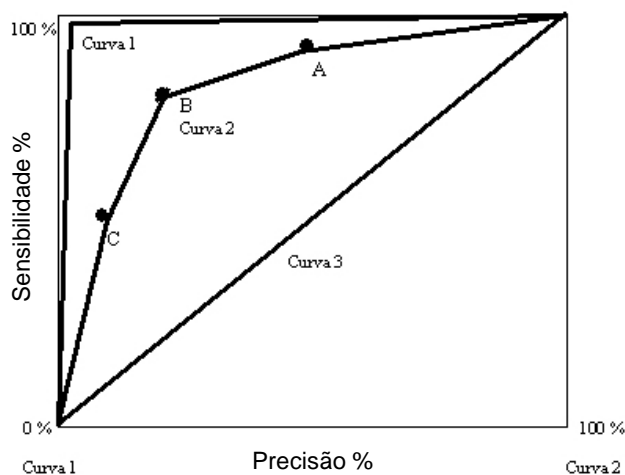


Métricas de performance

Curva ROC (Receiver Operating Characteristic)

● Possui dois parâmetros:

- Taxa de verdadeiro positivo = Precisão
- Taxa de falso positivo = sensibilidade





Métricas de performance

MAE (Mean Absolute Error)

- O erro absoluto médio é a média da diferença entre os valores originais e os valores previstos
- Ele nos dá a medida de quão longe as previsões estavam do resultado real

$$MAE = \frac{\sum(y_i - \hat{y}_i)}{n}$$

MSE (Mean Squared Error)

- Considera a média do quadrado da diferença entre os valores originais e os valores previstos
- Usar o erro ao quadrado aumenta o impacto dos erros maiores. Esta propriedade é essencial quando se pretende que o modelo tenha erros mais pequenos.

$$MSE = \frac{\sum(y_i - \hat{y}_i)^2}{n}$$




Métricas de performance

RMSE (Root Mean Squared Error)


- É a raiz do erro médio quadrático
- Conforme os valores de erros das instâncias aumentam o índice do RMSE aumenta consideravelmente.
- Se houver um outlier no conjunto de dados, seu peso será maior para o cálculo do RMSE

$$RMSE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n}}$$

Erros pequenos



Erros a partir de 1





Obrigado!

Perguntas?

🕒 krigor.silva@edu.udesc.br