

Relatório de IA sobre ant clustering

Paulo H. Gonçalves¹

¹ Departamento de Ciência da Computação
Universidade do Estado de Santa Catarina (UDESC) – Joinville, SC – Brazil

Paulohgon01@gmail.com

Abstract. *This article focuses on analyzing algorithms that simulate the cooling of metals, utilizing this concept to optimize solutions for problem functions. It conducts a global search for results when the temperature is high and a local search when the temperature is low. The temperature decreases based on an equation that takes into account the number of iterations. A comparison will be made with the random search algorithm to establish an efficiency benchmark.*

Resumo. *Este artigo preocupa-se em fazer uma análise sobre algoritmo que simulam o resfriamento de metais utilizando essa ideia para otimizar soluções de funções problema, fazendo uma busca global dos resultados quando a temperatura esta alta e busca local quando a temperatura esta baixa, e a temperatura abaixa em função de uma equação que leva em conta a quantidade de iterações. Será feita a comparação desse algoritmo random search para ter uma base de eficiência.*

1. Introdução

Simulated Annealing é um algoritmo de otimização probabilístico que é inspirado pelo processo de resfriamento controlado de um material para diminuir seu estado de energia até alcançar um estado de mínimo global. Ele é comumente utilizado para resolver problemas de otimização global, onde o objetivo é encontrar a melhor solução em um espaço de busca grande e complexo.

O algoritmo utiliza uma variável chamada "temperatura", que controla a probabilidade de aceitar soluções piores do que a solução atual que fora gerada. No início, a temperatura é alta, permitindo que o algoritmo aceite soluções piores com uma alta probabilidade. Isso ajuda o algoritmo a evitar ficar preso em vales sem solução e explorar o espaço de busca de forma mais global.

À medida que o algoritmo progride, a temperatura é gradualmente reduzida de acordo com uma função de resfriamento específica. À medida que a temperatura diminui, a probabilidade de aceitar soluções piores também diminui. Isso significa que o algoritmo se torna cada vez mais focado em buscar soluções melhores e converge para um mínimo global ou uma solução ótima, dependendo do problema em questão.

A capacidade do Simulated Annealing para escapar de mínimos locais e explorar o espaço de busca de maneira eficaz faz dele uma técnica poderosa para uma variedade de problemas de otimização, como o problema do 3 sat, que será abordado nesse artigo.

2. Metodologia de desenvolvimento

O primeiro passo do desenvolvimento é definir a fórmula de decaimento de temperatura. Por conta da facilidade de desenvolvimento e não levar em conta a temperatura atual ou temperatura inicial. Foi escolhido a formula

$$T = (1 - \frac{iteracao}{maximodeiteracao})^t$$

Onde *iteracao* é a iteração atual do algoritmo e *maximodeiteracao* é o número de iterações máximas do algoritmo, aqui escolho 250.000. Além disso, *t* é a taxa de resfriamento do algoritmo, escolhido aqui arbitrariamente como 10.

Outros pontos que foram escolhidos é a frequência que a queda de temperatura chamado SAMAX, que nesse algoritmo é 5, ou seja, a cada 5 iterações a temperatura será recalculada e diminuída.

Além disso, também é escolhido a quantidade de variáveis que será trocada a cada geração de vizinho, nesse algoritmo ela é dinâmica, ou seja, ela começa com 5, e vai diminuindo até 2 no fim do algoritmo.

Agora, levando em conta essa fórmula de resfriamento, será aplicado o método simulated annealing em problemas 3-SAT com 20, 100 e 250 variáveis junto com uma análise em comparação com random search.

3. O problema

O problema de 3-sat é basicamente um conjunto de variáveis booleanas ligadas por operadores booleanos and, not, or. É conhecido por ser um problema NP-completo que se baseia em descobrir se existe um conjunto de valores booleanos que, quando aplicados a fórmula no modelo 3-sat resultam em verdadeiro. Um exemplo de uma fórmula 3sat é:

$$(x_1 \vee \neg x_2 \vee x_3) \wedge (\neg x_1 \vee x_2 \vee \neg x_3) \wedge (\neg x_1 \vee x_2 \vee x_3)$$

Por ser NP completo achar uma solução em tempo polinomial para grandes instâncias desse problema ainda é um mistério, para isso então usamos a inteligência artificial, como será demonstrado em seguinte.

4. Random search

O random search é um algoritmo de otimização que busca de forma completamente aleatória escolher valores que resultem em uma solução, uma maximização ou minimização de uma função problema.

Ele é uma primeira abordagem para solução e é a base de comparação da maioria dos algoritmos de otimização. Então será o algoritmo usado para comparação nesse artigo. Utilizando as mesmas instâncias, mesmo hardware, mesma linguagem e mesmo ambiente.

5. Resultados

Agora será feita a análise de todas as instâncias e seus resultados, acompanhados de gráficos para simulated annealing e random search e no fim análise dos resultados com base na média e desvio padrão.

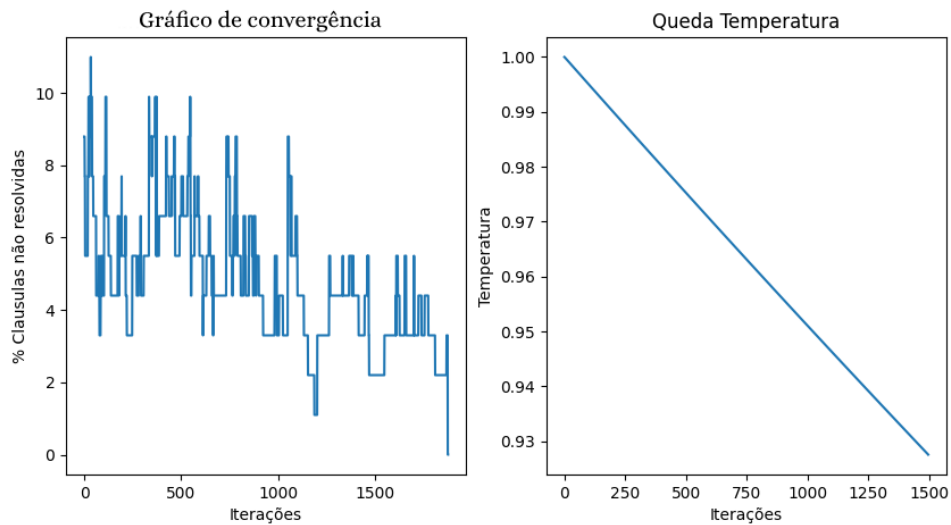


Figure 1. Simulated annealing 20 variaveis

5.1. 20 variaveis

Nessa instância um algoritmo qualquer já resolveria e não demoraria muito, o próprio random search resolveu a maioria das instâncias. Enquanto o simulated annealing(SA) resolveu todas. Para ter essa noção iremos analisar o gráfico de convergência de ambos os algoritmos, enquanto o simulated annealing tem também a queda temperatura. Além disso terá por fim o box plot do simulated annealing.

Analisando os gráficos podemos perceber que o simulated annealing resolveu o problema 3-sat bem antes do random search. Uma vez que o random search atingiu o 0 pouco depois das 100.000 iterações enquanto o simulated annealing resolveu pouco depois das 1500 iterações. Mas, como já dito, uma instância desse problema com 20 variáveis é facilmente resolvida, vemos isso já que o simulated annealing resolveu as 10 vezes que foi executado e o random search resolveu 8. Também vemos isso ao analisar o box plot dos valores de clausulas não resolvidas do SA.

5.2. 100 variaveis

Já nessa quantidade de variáveis, o random search não foi capaz de resolver nenhuma das iterações, e o simulated annealing algumas. Porém nessa instância já se torna inviável a resolução não utilizando algoritmos de IA.

Analisar melhor esse gráfico do simulated annealing, na figura 4, para compreender o seu funcionamento. quando comparamos o grafico de convergencia com a queda de temperatura, é notável que, com a temperatura mais alta, a variância de resultados é muito maior, ou seja o algoritmo está fazendo uma busca global, e conforme a temperatura vai caindo, ele muda para uma busca mais local e com menos variância de resultados, convergindo por fim ao resultado de resolver todas as clausulas, nesse ponto o algoritmo para a execução.

Enquanto o random search na figura 5 não resolveu nenhuma das 10 vezes que foi executado, ficando geralmente acima de 90% de resolução. Mas já é perceptível por que usar um algoritmo mais inteligente como o SA.




Figure 2. Random search 20 variaveis




Figure 3. Boxplot dos valores de clausulas não resolvidas do SA

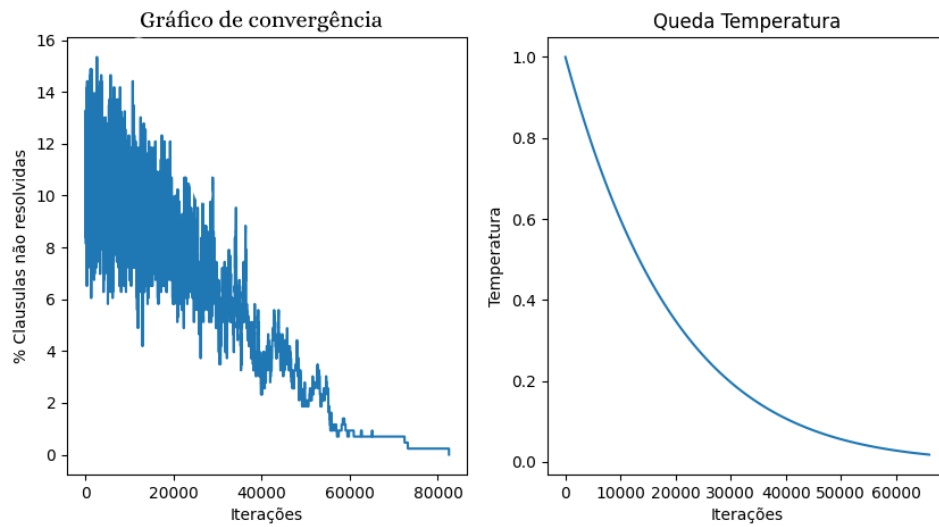


Figure 4. Simulated annealing para 100 variaveis




Figure 5. Random search para 100 variaveis

Por fim temos também o boxplot na figura 6 dos retornos de todas as 10 execuções do simulated annealing, onde podemos analisar melhor as respostas. Nessa instância, foram resolvidas 4 das 10 execuções, enquanto as outras resolveram cerca de 99% das clausulas




Figure 6. BoxPlox das quantidades da clausulas nao resolvida de cada execucao SA

5.3. 250 variaveis

Por fim temos a instância de 250 variaveis, essas que foram um desafio maior até para o algoritmo SA, ja para o random search, novamente, nenhuma execucao teve um retorno positivo.




Figure 7. Simulated Annealing para 250 variaveis

Analisando o grafico de convergencia na figura7 podemos perceber como essa instância exigiu mais tempo do algoritmo SA, pois sua solução foi retornada somente proximo das 250000 iterações, que é o número maximo de iterações. É notável também o gráfico de queda de temperatura sendo executada com mais tempo, assim podemos ter mais noção do funcionamento da função de resfriamento, que leva em consideração a quantidade de iterações.




Figure 8. Random search para 250 variaveis




Figure 9. BoxPlox das quantidades da clausulas nao resolvida de cada execução SA

Já no algoritmo de random search na figura 8, percebemos que já não faz mais sentido utiliza-lo, pois a cada vez que aumentamos a quantidade de variáveis, a porcentagem que cláusulas não resolvidas aumenta, demonstrando a baixa eficiência do algoritmo

nesses cenários e evidenciando o motivo de usarmos o SA.

Por fim, na figura 9 temos o boxplot da quantidade de clausulas nao resolvidas em todas as execuções do SA, para melhor analise.

5.4. Média e desvio padrão

Para facilitar a análise dos resultados, foi gerado tabelas comparando o desvio padrão e média de cada um deles. Com isso, podemos analisar como nesses casos o algoritmo simulated annealing é superior em todas as instâncias.

Para o cálculo desses valores foi utilizado a quantidade de clausulas não resolvidas no final de cada execução, e foram 10 execuções para cada instância de problema.

| Número de Variáveis | Média de clúsulas não resolvidas | |
|----------------------|----------------------------------|---------------------|
| | Random Search | Simulated Annealing |
| 20 Variáveis | 0.2 | 0 |
| 100 Variáveis | 25.5 | 1.0 |
| 250 Variáveis | 84.8 | 1.2 |

| Número de Variáveis | Desvio padrão de clausulas não resolvidas | |
|----------------------|---|---------------------|
| | Random Search | Simulated Annealing |
| 20 Variáveis | 0.42 | 0.0 |
| 100 Variáveis | 1.35 | 1.05 |
| 250 Variáveis | 2.74 | 0.78 |

6. Conclusão

Em síntese, considerando o desafio e objetivo proposto, podemos concluir que o algoritmo de SA é mais eficiente que o random search, pelo menos quando aplicado para a resolução do 3SAT. Porém, também é claro que existe a necessidade da execução do algoritmo diversas vezes para talvez conseguir uma solução completa. No caso das instâncias propostas todas tinham solução, assim como demonstrado, mas poderiam não possuir, e assim seria necessário executar diversas vezes e depois analisar a media e desvio padrão dela, tal como feito em ambas as tabelas feitas.

References