

# INTELIGÊNCIA ARTIFICIAL

## REDES NEURAIS ARTIFICIAIS






---

Krigor R. Rosa da Silva  
krigor.silva@edu.udesc.br




## Leitura





## Redes Neurais Artificiais (RNA)

- São um **subcampo** da inteligência artificial que tenta modelar o comportamento do cérebro humana para resolver **problemas complexos**;
- Consistem em um **conjunto interconectado** de neurônios artificiais que trabalham juntos para aprender e realizar tarefas;





## Redes Neurais Artificiais (RNA)

- Habilidade de adquirir e armazenar conhecimento para realizar uma tarefa;
- São caracterizados por uma unidade de processamento chamada neurônio artificial;
- Cada neurônio é ligado por sinapses artificiais;
- Computacionalmente, são representadas por matrizes e vetores de pesos sinápticos;



## Redes Neurais Artificiais (RNA)

### APRENDER

A partir de amostras  
de treinamento

### GENERALIZAR

A partir do  
conhecimento  
adquirido

### ADAPTAR

Ajustando-se a uma  
nova realidade



## Histórico

---

- McCulloch e Putts (1943) -> Ideia de máquinas inspiradas no cérebro
  - Donald Hebb (1949) -> The Organization of Behavior (Lei de aprendizagem das sinapses)
  - Frank Rosemblat (1958) -> Primeiro neuro computador (Perceptron)
- 
- Rumelhart, Williams e Hinton (1986) -> Backpropagation
  - Deep Blue vence o campeão mundial de xadrez (1997)

**PORQUE O BOOM ATUAL?**



## Histórico


### SURGIMENTO DAS GPUS

Voltada inicialmente para renderização de imagens e vídeos;

Pesquisadores de inteligência artificial começaram a observar o processamento por GPU e aplicá-lo em redes neurais;



CPU  
MULTIPLE CORES



GPU  
THOUSANDS OF CORES



# Aplicações



Natural  
Language  
Processing



Entre muitas outras...





## Vantagens

---

- Capacidade de aprender
- Capacidade de generalização
- Tolerância a falhas e ruído
- Automação e eficiência
- Não precisa de um modelo matemático



## Desvantagens

---

- Requerem conjuntos de dados grandes
- Alta exigência computacional
- Problemas de aprendizagem
- Necessita o ajuste de parâmetros



## Quando Usar?

---

Existe um algoritmo (modelo matemático) que seja satisfatório para o problema em questão?


● **SIM** -> Use o algoritmo/modelo matemático

● **NÃO** -> Pode ser usado RNA



## Inspiração Biológica


- O cérebro faz com que tarefas de classificação pareçam fáceis;
- O processamento cerebral é realizado por redes de neurônios;
- Cada neurônio é conectado a vários outros neurônios;





## Inspiração Biológica


- Diversos sinais são recebidos através de outros neurônios ou terminações nervosas;
- Os sinais podem ser recebidos com diferentes intensidades nas sinapses receptoras;
- Sob circunstâncias apropriadas, o neurônio “dispara” um sinal elétrico em direção à saída;





## Inspiração Biológica

Representação matemática de um neurônio...





## Inspiração Biológica


---

- Perceptron é uma unidade básica de processamento neural;
- Modelo simples que recebe entradas, processa-as e produz uma saída;
- A medida que o algoritmo de treinamento é executado, os pesos são atualizados até que o modelo seja capaz de produzir a saída desejada;



## Inspiração Biológica

- $x_1, x_2, \dots, x_n$  são os sinais de entrada
- $w_1, w_2, \dots, w_n$  são os pesos das sinapses
- $\Sigma$  é a função soma, sua função é agregar os sinais de entrada produzindo um valor potencial de ativação.
- $\theta$  é o bias do neurônio, e identifica o patamar apropriado para o resultado produzido pelo combinador linear








## Modelagem

- $u$  é o potencial de ativação, produzido pela combinação linear
- $g$  é a **função de ativação** do  $k$ -ésimo neurônio
- $y_k$  é a saída do  $k$ -ésimo neurônio




$$u_k = \sum_{j=1}^m w_{kj} x_j$$

$$y_k = g(u_k + \theta_k)$$



## Bias



- O bias é um parâmetro que adiciona uma constante;
- É usado para ajustar a saída da função de ativação;
- Sem ele podemos ficar restritos a soluções limitadas;





## Problemas Tratáveis


- Usada para problemas linearmente separáveis;





## Problemas Tratáveis

- ☉ Efeito do bias sobre o neurônio artificial;





## Funções de Ativação


---

- Decidem se um neurônio **deve ser ativado ou não**;
- A ativação é utilizada para **introduzir não-linearidades** nos modelos e permitir que as redes aprendam funções mais complexas;
- Uma rede sem função de ativação é apenas um modelo de regressão linear;
- A escolha da função depende da arquitetura da rede e tarefa a ser realizada;




## Funções de Ativação


0/1 step




-1/+1 step




relu:  $\max(0, x)$



sigmoid:  $1/(1+e^{-x})$



tanh:  $(e^x - e^{-x})/(e^x + e^{-x})$






## Exemplo

Problema de classificação

$x_1$	$x_2$	$x_3$	Classe
2	5	2	1

$$soma = \sum_{j=1}^m w_j * x_j$$






## Exemplo

Problema de classificação

$x_1$	$x_2$	$x_3$	Classe
2	5	2	1








## Redes de Neurônios

- Da mesma forma que os neurônios biológicos são organizados em camadas, podemos organizar os neurônios artificiais em camadas





## Redes de Neurônios



---

- Neurônios da mesma camada tipicamente possuem o mesmo comportamento (função de ativação e padrão de conexões);
- O arranjo de neurônios em camadas e o padrão de interconexão é conhecido como arquitetura da rede;
- Arquiteturas típicas
  - Rede camada única
  - Rede de múltiplas camadas



## Camada Única



- Exemplo: Redes de Kohonen ou mapas auto-organizáveis;
- Usada para detectar similares, regularidades, correlações e agrupamentos;
- Baseada em aprendizagem não-supervisionada;





## Multicamadas


- Formadas por várias camadas de neurônios artificiais interconectados;
- Aprendizado com dados complexos, identificação de padrões;
- Treinamento é realizado por um **algoritmo de retropropagação de erro**, processo é repetidos várias vezes até que um **erro aceitável** seja encontrado;





## Definição de camadas

- ⦿ Nem sempre mais camadas significam melhores resultados;
  - Pode levar ao **overfitting** (ajuste excessivo dos dados de treinamento)
- ⦿ Depende da complexidade do problema;





# Obrigado!

## *Perguntas?*

🕒 [krigor.silva@edu.udesc.br](mailto:krigor.silva@edu.udesc.br)



## Exercício

- Atividade de desenvolvimento de perceptron;
- Testar funções de ativação: Step, Sigmoid e Relu;
- Valores de peso podem ser escolhidos aleatoriamente;

Comprimento da Sépala	Largura da sépala	Comprimento da Pétala	Largura da Pétala	Classe
5,1	3,5	1,4	0,2	1
4,9	3,0	1,4	0,2	1
6,1	2,9	4,7	1,4	2
6,4	3,1	5,5	1,8	2

